

# Inteligencia Predictiva en la Retención de Clientes

De los Datos Crudos a la Estrategia Financiera y la Arquitectura TI

Un análisis de gobernanza tecnológica para directores





# El Motor Predictivo Central

Detrás de esta matriz de algoritmos y métricas generada en milisegundos, se esconde una decisión crítica. Elegir la fila incorrecta no solo afecta la precisión matemática; define el desperdicio del presupuesto de marketing y el colapso de los costos de servidores en la nube.

| Model                                      | Accuracy | AUC    | Recall | Prec.  | F1     | Kappa  | MCC    | TT (Sec) |
|--------------------------------------------|----------|--------|--------|--------|--------|--------|--------|----------|
| lr (Logistic Regression)                   | 0.7689   | 0.8047 | 0.5602 | 0.7208 | 0.6279 | 0.4641 | 0.4736 | 1.5090   |
| ridge (Ridge Classifier)                   | 0.7670   | 0.0000 | 0.5497 | 0.7235 | 0.6221 | 0.4581 | 0.4690 | 0.0360   |
| lda (Linear Discriminant Analysis)         | 0.7670   | 0.8055 | 0.5550 | 0.7202 | 0.6243 | 0.4594 | 0.4690 | 0.0680   |
| rf (Random Forest Classifier)              | 0.7485   | 0.7911 | 0.5284 | 0.6811 | 0.5924 | 0.4150 | 0.4238 | 0.1640   |
| nb (Naive Bayes)                           | 0.7427   | 0.7955 | 0.5702 | 0.6543 | 0.6043 | 0.4156 | 0.4215 | 0.0490   |
| catboost (CatBoost Classifier)             | 0.7410   | 0.7993 | 0.5278 | 0.6630 | 0.5851 | 0.4005 | 0.4078 | 0.2030   |
| gbc (Gradient Boosting Classifier)         | 0.7373   | 0.7918 | 0.5550 | 0.6445 | 0.5931 | 0.4013 | 0.4059 | 0.0960   |
| ada (Ada Boost Classifier)                 | 0.7372   | 0.7799 | 0.5275 | 0.6585 | 0.5796 | 0.3926 | 0.4017 | 0.1100   |
| et (Extra Trees Classifier)                | 0.7299   | 0.7788 | 0.4965 | 0.6516 | 0.5596 | 0.3706 | 0.3802 | 0.1560   |
| qda (Quadratic Discriminant Analysis)      | 0.7282   | 0.7894 | 0.5281 | 0.6558 | 0.5736 | 0.3785 | 0.3910 | 0.0460   |
| lightgbm (Light Gradient Boosting Machine) | 0.7133   | 0.7645 | 0.5398 | 0.6036 | 0.5650 | 0.3534 | 0.3580 | 0.2690   |
| knn (K Neighbors Classifier)               | 0.7001   | 0.7164 | 0.5020 | 0.5982 | 0.5413 | 0.3209 | 0.3271 | 0.0590   |
| dt (Decision Tree Classifier)              | 0.6928   | 0.6512 | 0.5137 | 0.5636 | 0.5328 | 0.3070 | 0.3098 | 0.0500   |
| xgboost (Extreme Gradient Boosting)        | 0.6853   | 0.7516 | 0.4912 | 0.5620 | 0.5216 | 0.2887 | 0.2922 | 0.0840   |
| dummy (Dummy Classifier)                   | 0.6518   | 0.5000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0410   |
| svm (SVM - Linear Kernel)                  | 0.5954   | 0.0000 | 0.3395 | 0.4090 | 0.2671 | 0.0720 | 0.0912 | 0.0400   |

## Evaluación del Algoritmo

El matriz de ensamble del modelo métrica la pensumientos sus métricas, criterios de algoritmo revela y los algoritmo risarian los criterios de selección para automeras doclarar el mon-ovaluación del algoritmo.

## Impacto en Campañas

Optimización de optimización del presupuesto de marketing, para dovir marxritos en eestas vscaños o utilirziito en el nonde, preno:itanra:es presupuesto del nropecto en ROI.

## Escalabilidad Cloud

Eficiencia no costo de metrzo de servidores, con enlicanda y esnultarersa en imiito de la infraestructura y la escalabilidad en la essbructura que se hootramente la namionzzo de Cloud.



# Traducción al Negocio: Las Métricas Base


| Término Técnico       | Traducción al Negocio                                                                       | Impacto en Campaña                                                                             |
|-----------------------|---------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------|
| Accuracy (Exactitud)  | ¿En qué porcentaje general el modelo acierta si el cliente se va o se queda?                | Visión global, pero peligrosa si se analiza de forma aislada.                                  |
| Recall (Sensibilidad) | De todos los clientes que REALMENTE iban a fugar, ¿cuántos logró detectar el sistema?       | Un Recall alto significa que no se nos escapa casi ningún desertor.                            |
| Precision (Precisión) | De todos los clientes que el sistema MARCÓ como en riesgo, ¿cuántos realmente querían irse? | Una Precision alta significa que nuestras alarmas son de fiar y no gastamos en falsas alarmas. |



# Equilibrio y Separación: Las Métricas Avanzadas




El F1-Score es el promedio armónico. Penaliza los modelos que tienen un Recall altísimo pero una Precision terrible (o viceversa). Es la métrica del equilibrio perfecto.



AUC (Área bajo la curva) mide la capacidad del modelo para distinguir y separar ambas clases. Un AUC de 0.80 significa que hay un 80% de probabilidad de que el modelo asigne un mayor riesgo a un desertor real que a un cliente leal.



# El Espejismo del Desbalance



Sistema Defectuoso: Nadie se va a fugar

→ **Accuracy = 99%**



Clientes Leales



Cliente en Fuga

¡El modelo sacó 99% de Exactitud, pero la empresa perdió a su único cliente en riesgo!

¿Por qué estas métricas son más confiables que el Accuracy?

Kappa y MCC (Coeficiente de Correlación de Matthews) corrigen este espejismo matemático. Evalúan el rendimiento real considerando la proporción de las clases. Si tu base de datos tiene un 2% de fuga, el Accuracy te mentirá; Kappa y MCC revelarán si tu modelo realmente aprendió o solo está adivinando lo más obvio.



# La Campaña de Retención (Reglas del Juego)

A cada cliente marcado en riesgo, le regalaremos un mes de servicio. Esta acción cuesta dinero. Nuestro objetivo financiero es maximizar la retención minimizando el desperdicio del presupuesto.

## Matriz de Confusión Financiera

| Realidad del Cliente |         | Predicción del Modelo                                                                  |                                                                                         |
|----------------------|---------|----------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------|
|                      |         | En Riesgo                                                                              | No en Riesgo                                                                            |
| Realidad del Cliente | En Fuga | <b>Cliente Salvado</b><br>El mes gratis fue una inversión exitosa.                     | <b>Gasto Desperdiciado</b><br>Le dimos un mes gratis a alguien que JAMÁS pensó en irse. |
|                      | Leal    | <b>Fuga Invisible</b><br>El cliente canceló y el sistema nunca avisó. Perdimos su LTV. | <b>Ahorro Efectivo</b><br>Cliente leal que no requirió incentivos.                      |




# Escenario A: La Estrategia de Red de Arrastre

Modelo con el mejor Recall (Naive Bayes)

|    |             | Merjz. | Dng.   | Recall: | Banor. | Apov.  | Target. | Recall | Result |
|----|-------------|--------|--------|---------|--------|--------|---------|--------|--------|
| nb | Naive Bayes | 0.7427 | 0.7955 | 0.5702  | 0.6543 | 0.6043 | 0.4156  | 0.4215 | 0.0490 |

Al priorizar el Recall, nuestra red detectará a casi todos los que desean abandonar el servicio.

El Problema Financiero: Al ser una red tan amplia, capturará muchos Falsos Positivos.



Le regalaremos el mes gratis a una enorme cantidad de clientes que no tenían intención de irse, generando un alto costo de gasto desperdiciado para la empresa.




# Escenario B: La Estrategia de Francotirador

## Modelo con la mejor Precision (Ridge Classifier)

| Model | Accuracy | AUC    | Recall | Prec.  | F1     | Kappa  | MCC    | TT (Sec) |
|-------|----------|--------|--------|--------|--------|--------|--------|----------|
| ridge | 0.7670   | 0.0000 | 0.5497 | 0.7235 | 0.6221 | 0.4581 | 0.4690 | 0.0360   |

Al priorizar la Precision, cada vez que el sistema dispara una alerta, es casi seguro que el cliente estaba a punto de irse.

## El Problema Financiero



Ahorramos muchísimo dinero porque no hay gasto desperdiciado, pero nuestro láser es tan estricto que se nos escaparán muchos clientes por el punto ciego (**Falsos Negativos**), cancelando sin que el sistema los detecte.



# El Veredicto Estratégico (Trade-off)

Como directivos, la elección del modelo no depende de la matemática, depende del Costo de Negocio.

Si regalaremos 1 mes  
(Costo Bajo) y el LTV es  
altísimo:

**Seleccionamos el  
Escenario A  
(Mejor Recall).**

Preferimos asumir el  
desperdicio del mes gratis con  
tal de no perder un cliente  
valioso.



Si regalamos hardware  
costoso o los márgenes  
son mínimos:

**Seleccionamos el  
Escenario B  
(Mejor Precision).**

No podemos darnos el lujo de  
regalar incentivos a quienes  
no se iban a ir. Protegemos el  
flujo de caja.




# Escalabilidad TI: De 50 Mil a 10 Millones

El Tiempo Técnico (TT Sec) representa el costo computacional subyacente.

Un modelo que funciona perfectamente en el laboratorio de Data Science con 50,000 registros puede convertirse en un cuello de botella catastrófico al desplegarse en arquitecturas Cloud para ingestar datos de 10 millones de usuarios diarios.


| Model                                      | TT (Sec) |
|--------------------------------------------|----------|
| lr (Logistic Regression)                   | 1.5090   |
| ridge (Ridge Classifier)                   | 0.0360   |
| lda (Linear Discriminant Analysis)         | 0.0680   |
| rf (Random Forest Classifier)              | 0.1640   |
| nb (Naive Bayes)                           | 0.0490   |
| catboost (CatBoost Classifier)             | 0.2030   |
| gbc (Gradient Boosting Classifier)         | 0.0960   |
| ada (Ada Boost Classifier)                 | 0.1100   |
| et (Extra Trees Classifier)                | 0.1560   |
| qda (Quadratic Discriminant Analysis)      | 0.0460   |
| lightgbm (Light Gradient Boosting Machine) | 0.2690   |
| knn (K Neighbors Classifier)               | 0.0590   |
| dt (Decision Tree Classifier)              | 0.0500   |
| xgboost (Extreme Gradient Boosting)        | 0.0840   |
| dummy (Dummy Classifier)                   | 0.0410   |
| svm (SVM - Linear Kernel)                  | 0.0400   |





# Arquitectura Subyacente: Ligeros vs. Pesados


## Modelos Ligeros



Ridge (0.0360s)  
Naive Bayes (0.0490s)

Matemáticas simples (álgebra lineal, probabilidad). Requieren mínimo cómputo.

## Modelos Pesados (Ensembles)




Random Forest (0.1640s)  
LightGBM (0.2690s)

Cientos de árboles de decisión anidados. Multiplican la necesidad de RAM y vCPUs.



# El Impacto de la Escalabilidad en AWS / Azure

¿Qué problemas enfrentaría al elegir algoritmos pesados en tiempo real?





# El Dilema del 2%: Precisión vs. Costo de Servidores

## Ridge Classifier

**Accuracy:** 0.7670

**TT (Sec):** 0.0360s (Súper Rápido)

## Logistic Regression

**Accuracy:** 0.7689

**TT (Sec):** 1.5090s (Extremadamente Lento)

**+0.19% Mejora Predictiva = 41X Costos de Servidor**

Desde la perspectiva de Arquitectura de Sistemas: ¿Se justifica ganar un margen mínimo en Accuracy si el algoritmo requiere multiplicar exponencialmente el tiempo de procesamiento? La respuesta suele ser NO. En producción masiva, la eficiencia computacional de modelos simples supera el perfeccionismo matemático.



# El Triángulo de Oro del Machine Learning

La revelación final: El mejor algoritmo de Inteligencia Artificial nunca es simplemente el que tiene la calificación más alta. El modelo verdaderamente exitoso es aquel que logra el punto de equilibrio exacto entre la detección matemática del riesgo, el costo financiero de la campaña, y la viabilidad económica en la nube.

